

ACT209 Projet final

Tarification de la fréquence des sinistres en assurance automobile

Comparaison entre GLM de Poisson et Gradient Boosting

Auteur : Xuan Hieu HO

Cours : ACT209 - Usage des large Language Models et du deep learning en assurance/finance

Répertoire du projet : act209_pricing_frequency

Déclaration d'usage d'un outil d'IA générative. ChatGPT (OpenAI) a été utilisé comme assistant ponctuel pour la structuration du projet, l'aide au codage, la relecture, la reformulation et la mise en forme du rapport. L'auteur demeure seul responsable du choix méthodologique, de l'exécution du code, de la vérification des calculs, de l'interprétation des résultats et du texte final. Cette mention explicite est incluse au titre de la transparence académique.

Résumé exécutif

Ce projet étudie la modélisation de la fréquence des sinistres pour un portefeuille d'assurance automobile à partir du jeu de données `freMTPL2freq`. L'objectif est de comparer une référence actuarielle classique, le GLM de Poisson, à un modèle d'apprentissage supervisé plus flexible, le Gradient Boosting avec perte de Poisson.

Les modèles prédisent une fréquence annuelle de sinistres. Les nombres attendus de sinistres sont ensuite reconstruits en multipliant la fréquence prédite par l'exposition. Cette distinction est essentielle : l'apprentissage porte sur une fréquence, mais l'évaluation actuarielle est réalisée sur l'échelle des nombres de sinistres attendus.

Le Gradient Boosting obtient la plus faible déviance de Poisson sur le test (0,305728) et le lift le plus élevé dans le dernier décile de risque (3,512816). Il apporte donc, dans cette étude, la meilleure performance prédictive et la meilleure segmentation des hauts risques.

Le GLM de Poisson reste toutefois indispensable comme benchmark actuariel. Il est plus simple, plus stable et plus directement interprétable. La recommandation finale est donc équilibrée : présenter le Gradient Boosting comme le modèle prédictif le plus performant de l'expérience, tout en conservant le GLM de Poisson comme référence actuarielle transparente.

Plan du rapport

- 1. Introduction
- 2. Données et cible actuarielle
- 3. Stratégie de modélisation
- 4. Résultats prédictifs globaux
- 5. Interprétation des modèles
- 6. Calibration et lift
- 7. Stabilité des prédictions
- 8. Cadre technique et reproductibilité
- 9. Discussion actuarielle
- 10. Limites et perspectives
- 11. Conclusion
- Références

1. Introduction

En assurance non-vie, la tarification technique repose en grande partie sur l'estimation de la fréquence et de la sévérité des sinistres. Ce rapport se limite volontairement à la composante fréquence. La sévérité, les frais, les contraintes commerciales et la construction complète d'une prime pure ne sont pas étudiés ici.

Le sujet est actuariel : il s'agit d'estimer, pour chaque contrat, une fréquence annuelle de sinistres en tenant compte de l'exposition.

$$Y_i^{\text{freq}} = \frac{N_i}{E_i}$$

où N_i désigne le nombre observé de sinistres et E_i l'exposition. Le modèle prédit une fréquence annuelle $\hat{\lambda}_i$, puis le nombre attendu de sinistres sur la période observée est reconstruit par :

$$\hat{\mu}_i = E_i \hat{\lambda}_i$$

L'étude compare trois niveaux de modélisation : un benchmark constant, un GLM de Poisson et un Gradient Boosting avec perte de Poisson. Le GLM est un modèle supervisé classique et constitue le benchmark actuariel. Le Gradient Boosting est également supervisé, mais il est plus flexible : il peut capter des non-linéarités et des interactions sans les spécifier explicitement.

L'objectif n'est pas de produire un tarif de production. Il est d'évaluer si un modèle d'apprentissage supervisé plus flexible améliore la performance prédictive hors échantillon et la segmentation des risques par rapport au benchmark actuariel de type GLM.

2. Données et cible actuarielle

2.1 Structure du portefeuille

Le jeu de données brut contient 678 013 polices d'assurance automobile et 12 variables initiales. Après création de la cible de fréquence, le fichier traité contient 13 colonnes. Le portefeuille comporte 36 102 sinistres observés et une exposition totale de 358 499,445 années d'exposition.

Le jeu de données `freMTP2freq` provient du package actuariel `CASdatasets`. Il correspond à des données françaises d'assurance automobile responsabilité civile et contient des variables de risque ainsi que le nombre de sinistres par police.

La fréquence annuelle globale observée est calculée comme le nombre total de sinistres divisé par l'exposition totale. Elle vaut 0,100703, soit environ 10,07 %. Cette grandeur est une fréquence pondérée par l'exposition ; elle ne doit pas être confondue avec la moyenne simple des fréquences individuelles `ClaimNb / Exposure`.

Indicateur	Valeur
Nombre de polices	678 013
Variables initiales	12
Sinistres observés	36 102
Exposition totale	358 499,445
Fréquence annuelle globale	0,100703

Tableau 1. Diagnostics globaux du portefeuille.




Figure 1. Distribution des nombres de sinistres observés.

La distribution des sinistres est très concentrée en zéro. Cette rareté relative des sinistres est habituelle en fréquence automobile et justifie l'utilisation de métriques adaptées aux nombres de sinistres, notamment la déviance de Poisson.

2.2 Exposition et variables explicatives

L'exposition est traitée comme une durée de risque. Elle n'est pas utilisée comme covariable ordinaire. Elle intervient comme poids d'observation lors de l'ajustement et comme multiplicateur permettant de passer de la fréquence annuelle prédite au nombre attendu de sinistres.

Les contrôles de qualité réalisés en amont ne signalent pas de valeurs manquantes critiques sur ClaimNb ou Exposure, pas d'exposition non positive et pas de nombre de sinistres négatif.




Figure 2. Fréquence observée par décile de BonusMalus.

La fréquence observée varie nettement selon BonusMalus. Le profil descriptif n'est pas parfaitement monotone, en particulier sur le premier décile ; cette observation doit être interprétée avec prudence car les déciles descriptifs dépendent de la structure du portefeuille et des rangs utilisés.

Rôle	Variables
Variables numériques	VehPower, VehAge, DrivAge, BonusMalus, Density
Variables catégorielles	VehBrand, VehGas, Area, Region
Variables exclues de X	IDpol, ClaimNb, Exposure, claim_frequency

Tableau 2. Variables utilisées dans le pipeline de modélisation.

3. Stratégie de modélisation

3.1 Échantillons d'apprentissage, validation et test

Échantillon	Polices	Exposition	Sinistres	Fréquence observée
Apprentissage	406 807	215 069,76	21 571	0,100298
Validation	135 603	71 805,26	7 290	0,101525
Test	135 603	71 624,42	7 241	0,101097

Tableau 3. Découpage apprentissage, validation et test.

Les fréquences observées sont proches entre les trois échantillons. Cela ne prouve pas une représentativité parfaite, mais ne révèle pas de déséquilibre évident de fréquence entre les jeux de données.

3.2 Modèles comparés

Le benchmark constant prédit la même fréquence annuelle pour toutes les polices. Il est estimé sur l'échantillon d'apprentissage comme le rapport entre le total des sinistres et le total des expositions. Il sert de niveau minimal de comparaison.

Le GLM de Poisson est le modèle actuariel classique de l'étude. Il utilise un lien logarithmique et donne des coefficients interprétables comme des effets multiplicatifs sur la fréquence prédite. Les variables numériques sont standardisées, les variables catégorielles sont encodées par indicatrices, et une modalité de référence est retirée pour le GLM non pénalisé.

Le Gradient Boosting est le modèle d'apprentissage supervisé flexible. Il est ajusté avec une perte de Poisson, un learning rate de 0,05, 100 itérations, 31 feuilles maximales par arbre et un minimum de 100 observations par feuille. Cette configuration est volontairement modérée ; elle n'est pas issue d'une recherche exhaustive d'hyperparamètres.

Dans le cadre GLM de Poisson, le nombre de sinistres est modélisé conditionnellement aux variables explicatives et à l'exposition :

$$N_i | X_i, E_i \sim \text{Poisson}(\mu_i), \quad \mu_i = E_i \lambda_i$$

La fréquence annuelle est ensuite reliée aux variables explicatives par un lien logarithmique :

$$\log(\lambda_i) = \beta_0 + X_i^\top \beta$$

$$\hat{\lambda}_i = \exp(\hat{\beta}_0 + X_i^\top \hat{\beta})$$

Cette écriture garantit des fréquences prédites positives et justifie l'interprétation de $\exp(\beta_j)$ comme effet multiplicatif sur la fréquence prédite.

Pour le Gradient Boosting, la prédiction est construite comme une somme progressive d'arbres de décision :

$$F_M(X_i) = F_0(X_i) + \sum_{m=1}^M \nu f_m(X_i)$$

$$\hat{\lambda}_i = \exp(F_M(X_i))$$

Un arbre découpe l'espace des variables explicatives en régions terminales appelées feuilles. Dans une feuille, les observations partagent une contribution prédictive locale. Les paramètres `max_leaf_nodes` et `min_samples_leaf` contrôlent respectivement la complexité maximale des arbres et la taille minimale des feuilles, ce qui limite le risque de surapprentissage.

3.3 Principe d'évaluation

La métrique principale est la déviance moyenne de Poisson calculée sur l'échelle des nombres de sinistres. Pour chaque police, l'évaluation utilise :

$$\hat{\mu}_i = E_i \hat{\lambda}_i$$

Une déviance plus faible correspond à une meilleure qualité prédictive.

La déviance moyenne de Poisson utilisée peut être écrite sous la forme suivante, avec la convention $\log(0 / \hat{\mu}_i) = 0$:

$$D = \frac{1}{n} \sum_{i=1}^n 2 \left[N_i \log \left(\frac{N_i}{\hat{\mu}_i} \right) - (N_i - \hat{\mu}_i) \right]$$

La déviance globale est complétée par une analyse de calibration par décile de risque prédit, une analyse de lift et une étude de stabilité des fréquences prédites. Ces diagnostics sont nécessaires, car un modèle peut avoir une bonne déviance globale tout en produisant des écarts locaux de calibration ou une queue de prédictions trop extrême.

4. Résultats prédictifs globaux

Modèle	Déviance train	Déviance validation	Déviance test	Écart val.-train	Écart test-train
Benchmark constant	0,330765	0,331719	0,331425	0,000954	0,000660
GLM de Poisson	0,320103	0,320796	0,321590	0,000693	0,001487
Gradient Boosting	0,298048	0,303698	0,305728	0,005650	0,007679

Tableau 4. Déviance moyenne de Poisson par modèle et échantillon.

Le Gradient Boosting présente la plus faible déviance de test : 0,305728, contre 0,321590 pour le GLM de Poisson et 0,331425 pour le benchmark constant.

Par rapport au GLM, la baisse relative de déviance de test est d'environ 4,93 %. Par rapport au benchmark constant, la baisse est d'environ 7,75 %. Ces améliorations mesurent un gain prédictif sur la déviance ; elles ne doivent pas être interprétées comme un gain direct de prime.

L'écart test-train est plus élevé pour le Gradient Boosting que pour le GLM. Ce résultat est cohérent avec la flexibilité plus grande du modèle et justifie les vérifications complémentaires de calibration, de lift et de stabilité.

5. Interprétation des modèles

5.1 Coefficients du GLM de Poisson

Variable	Coefficient	Effet multiplicatif	Effet en %
BonusMalus	0,348296	1,416652	+41,67 %
VehAge	-0,222863	0,800224	-19,98 %
DrivAge	0,092979	1,097439	+9,74 %
VehPower	0,027806	1,028197	+2,82 %
Density	0,016487	1,016623	+1,66 %

Tableau 5. Interprétation des coefficients numériques du GLM de Poisson.




Figure 3. Coefficients numériques du GLM de Poisson.

Comme les variables numériques sont standardisées, chaque coefficient numérique correspond à une augmentation d'un écart-type de la variable concernée, toutes choses égales par ailleurs.

Une augmentation d'un écart-type de BonusMalus est associée à une fréquence annuelle prédite environ 41,7 % plus élevée. À l'inverse, une augmentation d'un écart-type de VehAge est associée à une fréquence prédite plus faible d'environ 20,0 %. Ces résultats sont des associations issues du modèle ; ils ne doivent pas être interprétés comme des effets causaux.

5.2 Importance des variables pour le Gradient Boosting

Variable	Importance moyenne	Écart-type
VehAge	0,022781	0,000575
BonusMalus	0,022542	0,000605
VehBrand	0,010009	0,000534
DrivAge	0,004970	0,000364
VehGas	0,004031	0,000331
VehPower	0,003590	0,000350
Density	0,001305	0,000139
Region	0,000674	0,000148
Area	0,000047	0,000018

Tableau 6. Importance par permutation pour le Gradient Boosting.




Figure 4. Importance des variables par permutation pour le Gradient Boosting.

VehAge et BonusMalus sont les deux variables les plus importantes selon l'importance par permutation. Cette importance est prédictive : elle mesure la dégradation de la déviance de validation après permutation d'une variable. Elle ne constitue pas une preuve causale.

6. Calibration et lift

La calibration est étudiée en triant les polices de test selon la fréquence prédite, puis en divisant le portefeuille en dix déciles de risque prédit. Dans chaque décile, le nombre de sinistres observés est comparé au nombre de sinistres prédits. Le ratio de calibration est le rapport entre sinistres observés et sinistres prédits.

Pour un décile de risque prédit g , on note O_g le nombre de sinistres observés et P_g le nombre de sinistres prédits :

$$O_g = \sum_{i \in g} N_i, \quad P_g = \sum_{i \in g} \hat{\mu}_i = \sum_{i \in g} E_i \hat{\lambda}_i$$

Le ratio de calibration du décile g est alors :

$$\text{Cal}_g = \frac{O_g}{P_g} = \frac{\sum_{i \in g} N_i}{\sum_{i \in g} \hat{\mu}_i}$$

Un ratio proche de 1 indique une bonne calibration. Un ratio supérieur à 1 indique une sous-prédiction, tandis qu'un ratio inférieur à 1 indique une sur-prédiction.

Le lift mesure la capacité du modèle à classer les risques. Pour un décile g , il est calculé comme le rapport entre la fréquence observée du décile et la fréquence observée moyenne du portefeuille test :

$$\text{Lift}_g = \frac{\left(\sum_{i \in g} N_i \right) / \left(\sum_{i \in g} E_i \right)}{\left(\sum_i N_i \right) / \left(\sum_i E_i \right)}$$

Modèle	Erreur moy. abs.	Erreur max. abs.	Fréq. observée décile 10	Fréq. prédite décile 10	Lift décile 10
GLM de Poisson	0,005344	0,012756	0,222566	0,233303	2,201511
Gradient Boosting	0,004250	0,017106	0,355134	0,348393	3,512816

Tableau 7. Résumé de calibration et lift du dernier décile.




Figure 5. Calibration par décile de risque prédit.

Le Gradient Boosting présente une erreur moyenne absolue de calibration légèrement plus faible que le GLM, mais aussi une erreur locale maximale plus élevée. La conclusion correcte est donc nuancée : il n'est pas mieux calibré partout ; il est meilleur en moyenne mais moins régulier sur certains groupes.

Le dernier décile sélectionné par le Gradient Boosting contient 13 561 polices, 1 745 sinistres observés et une fréquence observée de 0,355134. Son lift vaut 3,512816, soit environ 3,51 fois la fréquence moyenne du portefeuille test.




Figure 6. Lift observé par décile de risque prédit.

Le résultat le plus marquant de l'analyse finale est le lift du dernier décile. Le Gradient Boosting isole beaucoup plus fortement les polices à haut risque que le GLM de Poisson, ce qui confirme sa meilleure capacité de segmentation.

7. Stabilité des prédictions et valeurs extrêmes

Modèle	Moyenne	Écart-type	Quantile 99 %	Quantile 99,9 %	Maximum
GLM de Poisson	0,107803	0,056744	0,323613	0,529880	3,885052
Gradient Boosting	0,114047	0,122715	0,636624	1,198751	9,760177

Tableau 8. Dispersion et queue haute des fréquences annuelles prédites.




Figure 7. Dispersion et queue haute des fréquences prédites.

Le Gradient Boosting produit une distribution de fréquences prédites plus dispersée. Son écart-type est environ 2,16 fois celui du GLM, et sa fréquence prédite maximale est environ 2,51 fois celle du GLM.

Ces valeurs élevées ne sont pas automatiquement fausses. Elles doivent cependant être surveillées avant tout usage opérationnel, notamment lorsque les polices concernées ont de faibles expositions ou des combinaisons rares de facteurs de risque. Une fréquence annuelle élevée doit toujours être interprétée conjointement avec l'exposition, car le nombre attendu est obtenu en multipliant l'exposition par la fréquence annuelle prédite.

8. Cadre technique et reproductibilité

Le projet est implémenté en Python avec une structure modulaire. Les notebooks portent le fil narratif de l'analyse, tandis que le dossier src contient les fonctions réutilisables de préparation, de preprocessing, de modélisation et de métriques.

Les principales bibliothèques utilisées sont pandas et numpy pour la manipulation de données, matplotlib pour les figures, et scikit-learn pour les prétraitements, le GLM de Poisson, le Gradient Boosting et l'importance par permutation. Le paramètre random_state = 42 est utilisé lorsque cela est pertinent.

Conformément à la déclaration de transparence figurant en page de titre, ChatGPT (OpenAI) a pu être utilisé comme assistant ponctuel pour la structuration du projet, l'aide au codage, la relecture, la reformulation et la mise en forme du rapport. Les calculs, les sorties numériques, les tableaux et les figures ont toutefois été vérifiés à partir des fichiers produits par les notebooks du projet.

Composant	Rôle
01_data_exploration.ipynb	Contrôles de données, cible et exploration descriptive
02_modeling_glm_gb.ipynb	Ajustement, validation et sauvegarde des prédictions
03_final_results.ipynb	Calibration, lift, stabilité et interprétation finale
src/data_preparation.py	Chargement, qualité des données et choix des variables
src/preprocessing.py	Imputation, standardisation et encodage one-hot
src/modeling.py	Construction des pipelines GLM et Gradient Boosting
src/metrics.py	Déviance de Poisson, calibration et lift

Tableau 9. Organisation technique du projet.

Les notebooks doivent être exécutés dans l'ordre depuis un noyau propre. Les sorties attendues comprennent les tableaux de performance, les prédictions test, les tables de calibration, les figures, les résumés de stabilité et les modèles sauvegardés. La séparation entre données brutes, données traitées, code, sorties et rapport facilite l'audit du projet.

9. Discussion actuarielle

Axe	GLM de Poisson	Gradient Boosting
Performance prédictive	Bonne	Meilleure dans cette étude
Interprétabilité	Élevée	Plus faible
Stabilité	Plus élevée	Plus faible
Calibration moyenne	Bonne	Légèrement meilleure
Calibration locale	Plus régulière	Moins régulière
Segmentation du risque	Modérée	Forte
Prédictions extrêmes	Moins extrêmes	Plus extrêmes

Tableau 10. Arbitrage principal entre les deux approches.

La conclusion empirique est un arbitrage, pas une victoire unilatérale. Le Gradient Boosting améliore la prédiction et la segmentation, mais le GLM reste plus transparent, plus stable et plus facile à expliquer dans un cadre actuariel.

Pour un projet pédagogique de tarification fréquence, la position la plus défendable est de retenir le Gradient Boosting comme meilleur modèle prédictif de l'étude, et de conserver le GLM de Poisson comme benchmark actuariel expliquant le sens et l'ordre de grandeur des effets.

10. Limites et perspectives

- Le projet modélise uniquement la fréquence ; la sévérité et la prime pure ne sont pas estimées.
- Les hyperparamètres du Gradient Boosting n'ont pas été sélectionnés par une recherche exhaustive.
- Les résultats dépendent du découpage apprentissage, validation et test choisi.
- L'importance par permutation mesure une contribution prédictive et non une influence causale.
- Le Gradient Boosting produit des fréquences prédites plus extrêmes et nécessiterait un suivi avant une utilisation opérationnelle.
- L'étude constitue un projet de modélisation pédagogique, pas un framework complet de tarification de production.

Les prolongements naturels seraient la modélisation de la sévérité, la construction d'une prime pure, une validation croisée, une recherche plus systématique d'hyperparamètres, des diagnostics de fairness et un suivi spécifique de la queue haute des prédictions.

11. Conclusion

Le projet montre qu'un modèle supervisé flexible peut améliorer la performance prédictive et le classement des risques par rapport à un GLM de Poisson classique sur ce jeu de données de fréquence automobile. Le Gradient Boosting obtient la plus faible déviance de test et le lift le plus élevé dans le dernier décile.

Le GLM de Poisson reste néanmoins un benchmark actuariel essentiel. Il est interprétable, stable et facile à communiquer. Sa structure fournit des effets multiplicatifs clairs, tandis que le Gradient Boosting doit être interprété indirectement par des diagnostics tels que l'importance par permutation, la calibration et le lift.

La conclusion finale est donc équilibrée : le Gradient Boosting est le modèle prédictif préféré dans cette étude, tandis que le GLM de Poisson doit être conservé comme modèle de référence transparent. Avant toute application opérationnelle, le Gradient Boosting exigerait un suivi complémentaire de la calibration, de la stabilité et des prédictions extrêmes.

Références

- [1] McCullagh, P. et Nelder, J. A. Generalized Linear Models. Chapman and Hall/CRC.
- [2] Goldburd, M., Khare, A. et Tevet, D. Generalized Linear Models for Insurance Rating. Casualty Actuarial Society.
- [3] Hastie, T., Tibshirani, R. et Friedman, J. The Elements of Statistical Learning. Springer.
- [4] James, G., Witten, D., Hastie, T. et Tibshirani, R. An Introduction to Statistical Learning. Springer.
- [5] Denuit, M., Marechal, X., Pitrebois, S. et Walhin, J.-F. Actuarial Modelling of Claim Counts. Wiley.
- [6] Ohlsson, E. et Johansson, B. Non-Life Insurance Pricing with Generalized Linear Models. Springer.
- [7] Frees, E. W., Derrig, R. A. et Meyers, G. Predictive Modeling Applications in Actuarial Science. Cambridge University Press.
- [8] Documentation scikit-learn : PoissonRegressor, HistGradientBoostingRegressor et permutation_importance.
- [9] Dutang, C. et Charpentier, A. CASdatasets: Insurance datasets. Dataset freMTPL2freq, French Motor Third-Party Liability frequency data. Available in the R package CASdatasets. URL : <https://dutangc.github.io/CASdatasets/reference/freMTPL.html>
- [10] Supports ACT209 et consignes d'évaluation du projet final.

Annexe - Vérification de reproductibilité

- Exécuter 01_data_exploration.ipynb depuis un noyau propre.
- Exécuter 02_modeling_glm_gb.ipynb depuis un noyau propre.
- Exécuter 03_final_results.ipynb depuis un noyau propre.
- Vérifier que tous les tableaux output_check retournent True.
- Confirmer que model_performance.csv, calibration_summary.csv et prediction_stability.csv correspondent aux valeurs utilisées dans ce rapport.