

ACT209 Projet final

Tarification de la fréquence des sinistres en assurance automobile

Comparaison entre GLM de Poisson et Gradient Boosting

Xuan Hieu HO

ACT209 - Usage des large Language Models et du deep learning en assurance/finance

Projet appliqué de fréquence de sinistres — présentation synthétique

1. Question actuarielle et périmètre

Le projet est volontairement centré sur la fréquence, pas sur la prime pure complète.

Question centrale

Un modèle plus flexible améliore-t-il la prédiction hors échantillon et la segmentation des risques par rapport au benchmark actuariel ?

Périmètre retenu

- fréquence annuelle des sinistres
- exposition utilisée comme poids et multiplicateur
- pas de sévérité, pas de frais, pas de prime commerciale

Cible et échelle d'évaluation

$$Y_i^{\text{freq}} = \frac{N_i}{E_i}$$

$$\hat{\mu}_i = E_i \hat{\lambda}_i$$

Idée clé

Le modèle apprend une fréquence annuelle. L'évaluation actuarielle est faite sur les nombres attendus de sinistres.

2. Données utilisées : freMTPL2freq

Portefeuille automobile français traité comme un problème de fréquence de sinistres.

678 013

polices

36 102

sinistres observés


358 499

années d'exposition

0,100703


fréquence globale

Distribution du nombre de sinistres observés



Sinistres rares : la masse est concentrée en zéro.

Fréquence observée par décile de BonusMalus



BonusMalus donne un signal descriptif fort, non parfaitement monotone.

Source : freMTPL2freq, CASdatasets. Les chiffres affichés correspondent au fichier effectivement traité.

3. Pipeline de modélisation

La démarche suit les consignes : préparation, modélisation, évaluation, limites.

01

Préparer

qualité des données,
cible, variables
explicatives

02

Apprendre

benchmark constant,
GLM de Poisson,
Gradient Boosting

03

Évaluer

déviance de Poisson,
calibration, lift, stabilité

04

Interpréter

coefficients GLM,
importance par
permutation, limites

Découpage

Échantillon	Polices	Fréquence
Apprentissage	406 807	0,100298
Validation	135 603	0,101525
Test	135 603	0,101097

Point de contrôle

Les fréquences observées sont proches dans les trois échantillons : aucun déséquilibre simple de fréquence n'est détecté.

4. Modèles comparés

Un benchmark simple, un benchmark actuariel et un modèle supervisé plus flexible.

Benchmark constant

Même fréquence annuelle pour toutes les polices.

Rôle : niveau minimal de comparaison.

GLM de Poisson

- modèle actuariel de référence
- lien log : prédictions positives
- coefficients interprétables

Gradient Boosting

- somme progressive d'arbres
- non-linéarités et interactions
- perte de Poisson

Formules utiles à connaître pour la soutenance

$$N_i \mid X_i, E_i \sim \text{Poisson}(E_i \lambda_i), \quad \log(\lambda_i) = \beta_0 + X_i^\top \beta$$

$$F_M(X_i) = F_0(X_i) + \sum_{m=1}^M \nu f_m(X_i), \quad \hat{\lambda}_i = \exp(F_M(X_i))$$

Lecture attendue

Ne pas opposer "actuariel" et "machine learning". Les deux modèles sont supervisés ; le Gradient Boosting est simplement plus flexible.

5. Performance prédictive hors échantillon

La métrique principale est la déviance moyenne de Poisson sur les nombres attendus.

Modèle	Déviance test
Benchmark constant	0,331425
GLM de Poisson	0,321590
Gradient Boosting	0,305728

Écart test-train : GLM 0,001487 ; GB 0,007679

Perte de Poisson utilisée pour comparer les modèles

$$d_i = 2 \left[N_i \log \left(\frac{N_i}{\hat{\mu}_i} \right) - (N_i - \hat{\mu}_i) \right], \quad \hat{\mu}_i = E_i \hat{\lambda}_i$$

Convention : si $N_i = 0$, le terme $N_i \log(N_i / \hat{\mu}_i)$ est pris égal à 0.

0,305728

Résultat principal

≈ 4,93 %

Gain relatif vs GLM


Interprétation

Le modèle plus flexible améliore la prédiction sur le test. En revanche, son écart test-train plus élevé impose des diagnostics complémentaires.


Attention : ce gain porte sur la déviance de test, pas directement sur une prime.

6. Interprétation : GLM lisible, GB plus flexible

Le GLM explique directement ; le Gradient Boosting s'interprète par diagnostics.



GLM : coefficients numériques sur variables standardisées.



GB : importance par permutation sur validation.

Lecture : BonusMalus augmente la fréquence prédite dans le GLM ; VehAge est associé à une fréquence plus faible.
Pour le GB, VehAge et BonusMalus dominent, puis VehBrand.


Point de rigueur : une importance prédictive n'est pas une causalité.

7. Calibration et lift : diagnostic clé de segmentation

Calibration et lift vérifient si les hauts risques sont bien identifiés et bien quantifiés.


Calibration

Compare les sinistres observés et prédits dans chaque décile de risque prédit.



Lift

Fréquence observée du décile / fréquence observée moyenne du portefeuille test.



Top décile GB : lift = 3,512816, soit environ 3,51 fois la fréquence moyenne du portefeuille test.

Conclusion : le Gradient Boosting segmente mieux les hauts risques, mais sa calibration locale reste à surveiller.

8. Stabilité des prédictions et prudence actuarielle

La meilleure segmentation s'accompagne de prédictions plus extrêmes.


Dispersion des fréquences prédites

GLM : écart-type 0,056744 | Q99,9 % 0,529880 | max 3,885052

GB : écart-type 0,122715 | Q99,9 % 1,198751 | max 9,760177

Ce que cela signifie

Le GB n'est pas "mauvais" parce qu'il prédit plus haut. Il concentre davantage le risque sur certains profils. Ces profils doivent être vérifiés avant usage opérationnel : exposition faible, combinaisons rares, surapprentissage local.



Message actuariel : performance, segmentation et stabilité doivent être jugées ensemble.

9. Conclusion

Une réponse équilibrée est plus défendable qu'une victoire unilatérale du modèle flexible.

1

Le Gradient Boosting est le meilleur modèle prédictif de cette expérience.

Déviance test plus faible et lift beaucoup plus élevé dans le dernier décile.

2

Le GLM reste indispensable comme benchmark actuariel.

Il est plus stable, plus transparent et plus facile à communiquer.

3

Avant un usage réel, il faut contrôler les extrêmes et compléter l'étude.

Sévérité, prime pure, validation croisée, hyperparamètres, fairness et suivi de calibration.

Réponse en une phrase

Oui : le Gradient Boosting prédit mieux hors échantillon et segmente mieux les hauts risques, mais le GLM reste le benchmark actuariel robuste et interprétable.

Transparence : l'IA générative a été utilisée comme assistant ; les calculs et résultats ont été vérifiés dans les notebooks.